

# 基于光谱偏差关系学习的 高光谱异常检测的一步法检测范式

## 摘要

高光谱异常检测 (HAD) 是指在无先验知识的情况下识别光谱偏离周围环境的目标。近年来, 基于深度学习的方法因其强大的光谱特征提取能力而成为了主流的 HAD 方法。但是, 目前的深度检测模型都是优化完成一个代理任务 (两步范式), 如背景重建或背景生成, 而不是直接实现异常检测。这导致了次优的结果和较差的可迁移性, 这意味着深度模型是在同一幅图像上训练和测试的。本文提出了一种无监督的转移直接检测 (TDD) 模型, 该模型直接针对异常检测任务 (一步范式) 进行了优化, 具有可转移性。特别是根据异常定义对 TDD 模型进行了优化, 以识别频谱偏离关系。与大多数模型学习特定的背景分布相比, 光谱偏差关系对不同图像具有普适性, 并保证了模型的可转移性。为了以无监督的方式训练 TDD 模型, 本文提出了一种异常样本模拟策略来生成大量的异常样本对。此外, 设计了全局自注意力模块和局部自注意力模块来帮助模型关注“光谱偏差”关系。TDD 模型在四个公开的 HAD 数据集上进行了验证。结果表明, 本文提出的 TDD 模型能够成功克服传统模型在单幅图像上训练和测试的局限性, 模型具有强大的检测能力和优异的可移植性。

**关键词:** 高光谱异常检测; 一步法范式; 可转移性; 深度学习

## 1 引言

由于丰富的光谱信息, 高光谱图像 (HIS) 可用于检测空间信息较少的异常。高光谱异常检测 (HAD) 旨在检测与周围环境光谱偏离的像素, 并且在许多领域被证明是有价值的, 包括染病树木检测, 稀有矿物检测和国防应用。通常异常在图像中占有很低的比例, 指的是人造目标、自然物体和其他干扰物。目前的 HAD 模型主要可以分为三类: 1) 基于统计的模型; 2) 基于表示的模型; 3) 基于深度学习的模型。近年来, 基于深度学习的方法因其强大的光谱特征提取能力而成为主流方法。然而, 目前基于深度学习的 HAD 模型遵循两步检测范式。第一步, 模型通过代理任务学习背景分布, 例如背景重建。第二步, 通过测量输入图像和重建背景之间的差异来识别异常。两步检测范式导致了两个严重的问题。1) 代理任务可能会得到次优的结果, 因为 HAD 代理任务的基本假设可能不成立。2) 训练好的模型缺乏对不同图像的可转移性, 因为它的目的是在训练阶段学习一定的背景分布。不同图像的背景分布不同, 这阻碍了可转移性。

本文针对 HAD 任务提出了一种转移直接检测 TDD 模型。TDD 模型直接输

出异常图，而不是重建背景，本文称之为“一步检测范式”。TDD 模型根据异常定义优化为“光谱偏离”关系，而不是特定的背景分布，使不同图像具有可转移性。在本文中，TDD 模型在四个公开的 HAD 数据集上进行了验证，其中 HYDICE 数据集用于无监督训练，其余数据集直接进行推断，无需进一步微调。结果表明，本文提出的 TDD 模型能够成功克服传统模型在单幅图像上训练和测试的局限性，具有强大的检测能力和出色的可移植性。

## 2 相关工作

### 2.1 基于统计的模型

基于统计的检测模型假设背景符合一定的统计分布，分布密度隐含了异常程度。RX 检测器<sup>[1]</sup>是一种里程碑式的统计方法，它假设背景服从高斯分布，并使用测试像素与得到的分布之间的马氏距离来衡量异常程度。受经典 RX 检测器的启发，一系列的扩展被提出。例如，Schaum<sup>[2]</sup>使用背景协方差的主成分在子空间中进行 HAD，以获得稳健的性能。类似地，核 RX 算法<sup>[3]</sup>被提出用于检测高维特征空间中的异常。Guo 等人<sup>[4]</sup>提出了基于加权 RX 和线性滤波器的 RX 检测器，以实现更好的背景估计。其他一些传统的检测器也是基于统计建模的，如流形学习检测器<sup>[5]</sup>和基于支持向量的检测器<sup>[6]</sup>。然而，基于统计的方法总是做出各种分布假设，例如高斯分布的假设，这可能在复杂背景中不成立，并可能导致不理想的检测结果。

### 2.2 基于表示的模型

基于表示的模型利用 HSI 的一些特性来检测异常，例如背景的低秩特性或异常的稀疏特性<sup>[7]</sup>。然后，获得的稀疏分量表示异常。低秩稀疏矩阵分解（LSDM）<sup>[8]</sup>通过将 HSI 分解为低秩背景和稀疏异常，已成功应用于 HAD 任务。Chen 等人<sup>[9]</sup>用鲁棒主成分分析 (RPCA) 算法实现了 LSDM 技术。Zhang 等人<sup>[10]</sup>更多地关注于低秩先验，并提出了一种新的基于马氏距离的检测器。Cheng 和 Wang<sup>[11]</sup>将空间信息融入其中图正则化和全变差正则化的低秩模型。最近，一些研究人员使用张量表示来反映 HIS 的 3D 结构<sup>[12]</sup>。例如，Li 等人<sup>[13]</sup>开发了一种基于先验的张量近似方法，该方法结合了低秩、稀疏和分段平滑先验与张量表示的优点。然而，上述基于表示的方法依赖于人工设计的先验和构造的背景字典，对高光谱图像中真实背景的特征能力有限。

### 2.3 基于深度学习的模型

基于深度学习的方法总是假设背景可以比异常更好地重建。它们遵循两步检测范式，其中第一步涉及训练深度重建模型，第二步涉及使用重建的背景输出检

测图。Li 等人<sup>[14]</sup>首次将卷积神经网络（CNN）引入到 HAD 中，以监督的方式检测异常。Wang 等人<sup>[15]</sup>提出了一个自主的高光谱异常检测网络（Auto-AD），其中背景由 AE 重建，异常表现为重建误差。还设计了自适应权重损失函数进一步抑制异常重构。Xie 等<sup>[16]</sup>提出了一种谱约束对抗 AE（SC\_AAE）来进行背景抑制和判别性表示提取。Wang 等人<sup>[17]</sup>设计了一种基于深度低秩先验的方法（DeepLR），该方法结合了模型驱动的低秩先验和数据驱动的 AE。Li 等人<sup>[18]</sup>提出了一种基于稀疏编码（SC）的 GAN 用于弱监督的 HAD，它学习到一个判别性的潜在重建，对背景像素的误差较小，对异常像素的误差较大。Arisoy 等人<sup>[19]</sup>训练了一个 GAN 模型来生成接近原始背景图像的合成背景图像。尽管性能优异，但两步检测范式会导致次优的结果和较差的可转移性。

### 3 本文方法

#### 3.1 本文方法概述

本文提出的 TDD 模型实现了一步检测范式，该模型直接输出异常图，并且可以迁移到不同的高光谱图像中。光谱偏差关系在传统两步范式中关注的是一步范式，而不是传统两步范式中的某个背景。本文设计了一个异常样本模拟策略，本文模型的架构基于 UNet 架构，主要的创新是解码部分的 GAM 和 LAM 的设计。

#### 3.2 一步检测范式

给定一幅高光谱图像  $X \in R^{H \times W \times B}$ ，其中 H、W 和 B 分别为图像的高度、宽度和波段数。HAD 任务是一个函数  $\phi$  将 X 映射到估计的检测图  $\hat{M} \in R^{H \times W}$ ，M 是地面真值， $X = BKG + A$ ，其中 BKG 为背景分量，A 为异常分量。 $\hat{M}$  的值表示对应像元的异常程度。为了克服这些限制，我们提出了一种一步检测范式，其中模型直接从 X 输出  $\hat{M}$ ，如（1）所示。一步模型不学习 BKG 或 A 的具体分布，而是学习 BKG 和 A 之间的统一关系  $R(BKG, A)$ ， $R(BKG, A)$  是对于 HAD 任务，是 A 相对于 BKG 的“光谱偏离”关系。模型优化目标直接最小化  $\hat{M}$  和 M 之间的差异，如（2）所示。

$$\phi: X \rightarrow \hat{M}(\text{learn}R(BKG, A)) \quad (1)$$

$$Loss = \text{Compare}(X, X') \quad (2)$$

#### 3.3 异常样本模拟策略

本文我们设计了一个由三个步骤组成的异常样本模拟策略，图 1 给出了其中的一个例子，步骤如下所示：

步骤 1：异常区域选择。将整个训练图像裁剪成图块后，依次对每个图块执

行该操作。由于高光谱异常一般为小目标，因此该过程在随机选择区域时需要控制异常区域大小，使得背景区域大于异常区域。对于输入补丁  $X$ ，处理后的补丁记为  $X_1$ 。选取的异常区域为矩形，并在  $X_1$  内进行掩膜。

步骤 2：异常光谱生成。为了产生光谱偏差，首先对图斑  $X$  的每个像素在光谱维度上进行随机洗牌，得到  $X_2$ 。假设斑块  $X$  的原始光谱为背景光谱，则  $X_2$  中的像元均为异常。接下来，在  $X_2$  中从过程 1 中截取掩膜区域的异常像素，并将其粘贴到  $X_1$  中，得到  $X_3$ 。

步骤 3：异常区域仿射变换。虽然  $X_3$  已经是可训练的异常样本， $X_3$  中的异常区域为均匀矩形，这与实际情况中异常具有不同形状的情况并不对应。为此，对  $X_3$  及其对应的标签  $Y_3$  进行随机仿射变换，以给出异常形状信息。应用的仿射变换是旋转、缩放和平移的组合序列。

总之，所设计的异常模拟策略在高光谱定义下融合了强异常位置随机性、光谱随机性和形状随机性。这些性质迫使模型学习一个“光谱偏离”的关系，而不是特定的背景或异常目标。

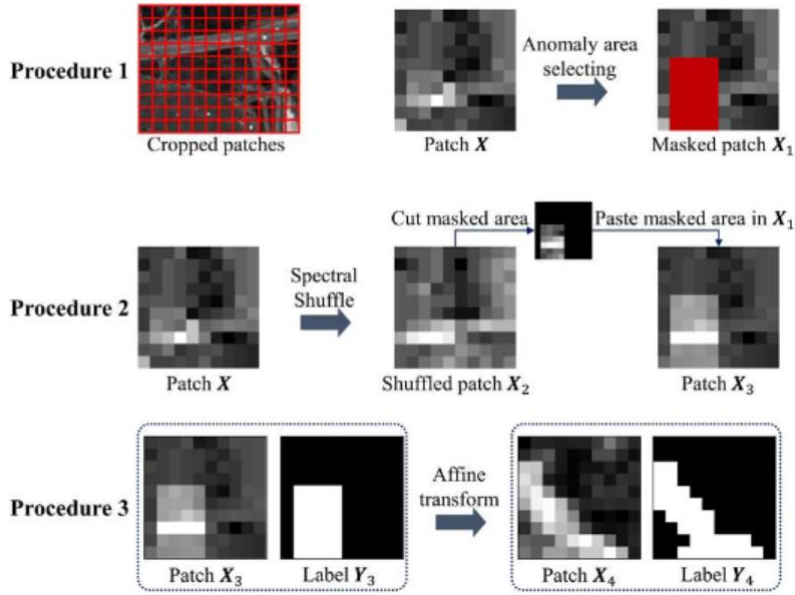


图 1. 异常样本模拟策略

### 3.4 模型架构

为了直接输出异常得分图，从而不依赖于任何后处理步骤，实现对 HAD 任务的直接优化，所提出的架构基于 UNet 架构<sup>[20]</sup>，具有编码和解码部分，如图 2 所示。编码器部分包含 6 个级联的特征提取模块，用于提取多尺度、多层次的特征。解码器部分依次包含编码块对应的解码块。编码器和解码器部分之间的跳跃连接有助于保持重要的空间信息。

主要的架构创新是解码部分的 GAM 和 LAM 的设计。由于我们期望模型能够学习到异常与背景之间的偏离关系，而不是依赖于特定的背景，因此对输入图像中像素之间的关系建模就显得尤为重要。自注意力机制有助于这一点，因为它们建模了相关性在每个像素和图像的其余像素之间，避免了卷积无法捕获长距离依赖的问题。GAM 计算所有像素的相关性，而 LAM 计算局部范围内像素的相关性。为了减少计算负担和抑制局部噪声，解码器使用交替的全局和局部感知注意力模块。所设计的自注意力模块可以即插即用，不需要改变原始特征图的空间大小和特征维度。

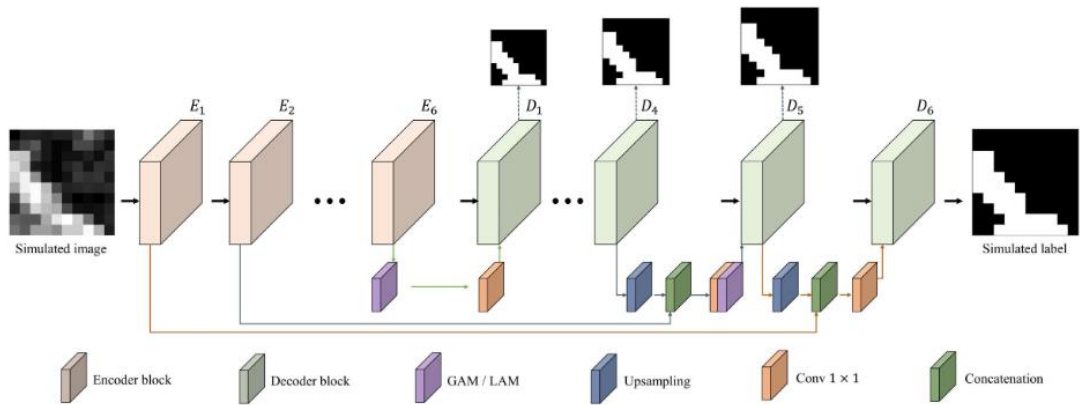


图 2. TDD 模型架构

## 4 复现细节

### 4.1 与已有开源代码对比

本文复现了作者所提出的 TDD 模型，并且改用了随机掩膜生成策略，添加多尺度梯度相似性损失函数来提升原文的性能表现，本文参考了他人的相关代码，链接如下：<https://github.com/Jingtao-Li-CVer/TDD>

### 4.2 实验环境搭建

操作系统	Windows 11 专业版
处理器	12th Gen Intel(R) Core(TM) i7-12650H 2.30 GHz
机带 RAM	16.0 GB
集成开发环境	PyCharm 2019.3.5 x64
Python	3.8
框架	Pytorch 2.0

## 5 实验结果分析

本部分对实验所得结果进行了分析，详细对实验内容进行了说明，并对实验结果进行了描述并分析。对 HYDICE 数据集检测得到的异常图如图 3 所示，可

以看出 TDD 检测出来的异常图中异常点与背景差异较大，效果较好；对 Cri 数据集检测得到的异常图如图 4 所示，TDD 模型可以完整地检测出异常区域，检测效果很好，虽然某些区域的亮度值较高，但与异常区域的亮度仍存在较大差异；对 AVIRIS-1 数据集检测得到的异常图如图 5 所示，TDD 模型较为准确的检测出了异常。




图 3.在 HYDICE 数据集上获得的异常检测结果。(a) 数据立方体 (b) 地面真值图 (c) TDD




图 4.在 Cri 数据集上获得的异常检测结果。(a) 数据立方体 (b) 地面真值图 (c) TDD




图 5.在 AVIRIS-1 数据集上获得的异常检测结果。(a) 数据立方体 (b) 地面真值 (c) TDD

本次实验采用 AUC 作为评价指标，AUC 是 ROC 曲线下的面积，用于定量评估分类器的性能。AUC 的取值范围在 0 到 1 之间。AUC 越大，表示模型对正例和负例的区分能力越好，性能越佳。表 1 展示了 TDD 模型、复现后的 TDD 模型和改进后的 TDD 模型分别在 HYDICE、Cri 和 AVIRIS-1 三个数据集上的 AUC

值。由表中可以看出，复现后的 TDD 模型在 HYDICE 和 AVIRIS-1 数据集上不如原论文模型的效果。但用改进后的 TDD 模型分别对于 HYDICE、Cri 和 AVIRIS-1 三个数据集进行测试，得到的 AUC 值更高，改进后的 TDD 比原始的模型所得到的 AUC 值更大，说明改进的模型的异常检测能力有一定的提高，也就是说改进后的 TDD 模型性能更好。

表 1. TDD 模型、复现后的 TDD 模型和改进后的 TDD 模型分别在三个数据集上的 AUC 值

数据集	Paper-TDD	Reproduce-TDD	Improved-TDD
HYDICE	0.9960	0.9843342393627024	0.9964136712364018
Cri	0.9915	0.9937998864746791	0.9966858701042306
AVIRIS-1	0.9728	0.8528205080908744	0.9762286004550386

## 6 总结与展望

本文提出了一种称为 TDD 模型的一步法 HAD 模型，该模型直接针对 HAD 任务进行优化，而不是像传统模型那样采用代理任务。TDD 模型关注光谱偏差关系，保证了模型的可迁移性，克服了传统模型在单幅图像上训练和测试的局限性。为了以无监督的方式训练 TDD 模型，提出了一种基于高光谱异常定义的异常样本模拟策略来生成大量的异常样本。为了帮助模型专注于上下文关系特征，我们设计了 GAM 和 LAM 模块来显式地学习偏离上下文。通过改用随机掩膜生成策略，添加多尺度梯度相似性损失函数提高了 TDD 模型的异常检测能力，但仍有较大的进步空间，需要在未来进一步的研究中进行进一步的改进。



## 参考文献

- [1] Reed I S, Yu X. Adaptive multiple-band CFAR detection of an optical pattern with unknown spectral distribution[J]. IEEE transactions on acoustics, speech, and signal processing, 1990, 38(10): 1760-1770.
- [2] Schaum A. Joint subspace detection of hyperspectral targets[C]//2004 IEEE Aerospace Conference Proceedings (IEEE Cat. No. 04TH8720). IEEE, 2004, 3.
- [3] Kwon H, Nasrabadi N M. Kernel RX-algorithm: A nonlinear anomaly detector for hyperspectral imagery[J]. IEEE transactions on Geoscience and Remote Sensing, 2005, 43(2): 388-397.
- [4] Guo Q, Zhang B, Ran Q, et al. Weighted-RXD and linear filter-based RXD: Improving background statistics estimation for anomaly detection in hyperspectral imagery[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2014, 7(6): 2351-2366.
- [5] Lu X, Zhang W, Huang J. Exploiting embedding manifold of autoencoders for hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 58(3): 1527-1537.
- [6] Gurram P, Kwon H. Support-vector-based hyperspectral anomaly detection using optimized kernel parameters[J]. IEEE Geoscience and Remote Sensing Letters, 2011, 8(6): 1060-1064.
- [7] Xie W, Zhang X, Li Y, et al. Weakly supervised low-rank representation for hyperspectral anomaly detection[J]. IEEE Transactions on Cybernetics, 2021, 51(8): 3889-3900.
- [8] Du L, Wu Z, Xu Y, et al. Kernel low-rank representation for hyperspectral image classification[C]//2016 IEEE International Geoscience and Remote Sensing Symposium (IGARSS). IEEE, 2016: 477-480.
- [9] Candès E J, Li X, Ma Y, et al. Robust principal component analysis?[J]. Journal of the ACM (JACM), 2011, 58(3): 1-37.
- [10] Zhang Y, Du B, Zhang L, et al. A low-rank and sparse matrix decomposition-based Mahalanobis distance method for hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2015, 54(3): 1376-1389.
- [11] Cheng T, Wang B. Graph and total variation regularized low-rank representation for hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 58(1): 391-406.
- [12] Sun S, Liu J, Chen X, et al. Hyperspectral anomaly detection with tensor average rank and piecewise smoothness constraints[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022.
- [13] Li L, Li W, Qu Y, et al. Prior-based tensor approximation for anomaly detection in hyperspectral imagery[J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 33(3): 1037-1050.
- [14] Li W, Wu G, Du Q. Transferred deep learning for anomaly detection in hyperspectral imagery[J]. IEEE Geoscience and Remote Sensing Letters, 2017, 14(5): 597-601.
- [15] Wang S, Wang X, Zhang L, et al. Auto-AD: Autonomous hyperspectral anomaly



detection network based on fully convolutional autoencoder[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 60: 1-14.

[16] Xie W, Lei J, Liu B, et al. Spectral constraint adversarial autoencoders approach to feature representation in hyperspectral anomaly detection[J]. Neural Networks, 2019, 119: 222-234.

[17] Wang S, Wang X, Zhang L, et al. Deep low-rank prior for hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-17.

[18] Li Y, Jiang T, Xie W, et al. Sparse coding-inspired GAN for hyperspectral anomaly detection in weakly supervised learning[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 60: 1-11.

[19] Arisoy S, Nasrabadi N M, Kayabol K. GAN-based hyperspectral anomaly detection[C]//2020 28th European Signal Processing Conference (EUSIPCO). IEEE, 2021: 1891-1895.

[20] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015: 18th International Conference, Munich, Germany, October 5-9, 2015, Proceedings, Part III 18. Springer International Publishing, 2015: 234-2